

Protocol A-SYNC

从发散到收敛

深层模型优化报告

算法变体报告 / 2026年7月

Protocol A 在 28+ 层模型上全部发散。
A-SYNC 用梯度注入替代直接权重写入。
Qwen2.5-7B (28L) : PPL 58.8 -> 7.6, 48周期单调收敛。

此前 7 种修复尝试 (调参、LARS、裁剪、多层 ALS 等) 全部失败。

1. 动机：为什么原始 Protocol A 失败

Protocol A 交替执行三个阶段：ALS (对 Im_head 精确逐块最小二乘求解)、SGD (对所有参数随机梯度下降) 和 Perturb (随机噪声注入)。在 12-24 层 Transformer 模型上可靠收敛。在 28 层及以上模型上，所有尝试均在 2-3 周期内发散。

根本原因：残差放大效应

ALS 仅
倍。经

Why Protocol A Fails on Deep Models




图1：左——残差放大曲线 $\rho^*(L-1)$ 与实验数据；右——跨深度基准测试结果。

模型
层数
放大倍数
Protocol A PPL

状态	
OPT-125m	
12	
2.3x	
106.9	
成功	
TinyLlama-1.1B	
22	
5.0x	
15.5	
成功	
Qwen2.5-0.5B	
24	
5.9x	
18.0	
成功（不稳定）	
Qwen2.5-7B	
28	
8.0x	
发散	
11/11 失败	




图2：Transformer 架构——ALS 仅修改 Im_head，扰动通过 L-1 个冻结块传播。

问题的根源是结构性的，而非参数性的。ALS 仅修改 Im_head 的设计，在 28 层模型中造成了 1600:1 的放大-恢复不对称。

2. A-SYNC 算法：梯度注入

核心创新

一个周期的伪代码：

```
2. delta = W_new - W_oldCPU GPU
3. lm_head W_old
4. SGD 50 sync_strength * delta lm_head
5. Perturb —
6. 1
```

最终配置：

```
learning_rate: 2e-4
momentum: 0.0, weight_decay: 0.01
cycles: 24-48 44
ALS: block_size=512, reg_lambda=1e-3, step_size=0.01
Perturb
```

A-SYNC 的设计哲学：ALS 计算该往哪里走（方向），SGD 负责如何走（优化）。两个信号正交（ $\cos=0$ ）且互补。




图3：算法模块应用矩阵——各变体修改哪些参数。A-SYNC（底部行）仅对 Im_head 进行梯度注入。

3. 所有修复尝试详述

参数调优 (alpha 和 ALS:SGD 比值) —— 失败

深度边界保护 —— 部分成功

LARS 优化器 —— 失败

多层 ALS (批量+顺序) —— 失败

A-PROBE (低秩瓶颈) —— 部分成功

A-SYNC (梯度注入) —— 成功

将
层模型

三重保
24 层。

逐层自

批量：
4864x4

在
Choles

ALS 计
永远不




图4：LARS vs SGD——GPT-2 12L (左) 和 Qwen0.5B 24L (右)。LARS 避免 NaN 但不收敛。

4. A-SYNC 变体演进

从第一个 A-SYNC 到最终收敛变体的演进路径：

#	变体	关键改动	7B 最终 PPL	状态
1	A-SYNC +perturb	梯度注入 + 噪声	25.8	振荡
2	A-SYNC no-perturb	移除扰动阶段	16.6	单调收敛
3	A-SYNC 16-cosine	余弦衰减	10.5	衰减过早
4	A-SYNC 32-cosine	32周期余弦	13.3	衰减杀尾
5	A-CYCLE restart	3x8 暖重启	16.5	窗口过短
6	A-SYNC 24-const	恒定同步 24c	9.0	优秀
7	A-SYNC 48-const	恒定同步 48c	7.6	最佳——已收敛




图5 : A-SYNC 在 Qwen2.5-7B (28L) 上的收敛曲线。48-constant (蓝色) 是明显的赢家。

关键发现：恒定的同步强度（0.05）支配所有衰减策略。ALS 信号应保持全强度——它是引导，不是退火。

5. 最终积分榜

方法	
类别	
Qwen7B (28L) PPL	
状态	
A-SYNC 48-constant	
梯度注入	
7.6	
已收敛	
Pure SGD	
基线	
22.5	
平台	
A-PROBE	
架构	
22.8	
瓶颈限制	
A-KD	
知识蒸馏	
195	
KL 爆炸	
LARS	
优化器	
161k	
未收敛	
多层 ALS	
算法	

- 发散
- 欠定
- 参数调优
- 调参
- 发散
- 不可迁移
- Protocol A（原始）
- 基线
- 发散
- 残差放大




图6：所有修复尝试积分榜——Qwen2.5-7B（28L）。A-SYNC 比纯 SGD 好 3 倍。

Depth Boundary: Before vs After




图7：Protocol A（左）在 28L 发散。A-SYNC（右）跨越边界——在所有深度上单调收敛。