

# ALS 残差放大问题：论文级分析

## 摘要

Protocol A (ALS→SGD→Perturb) 在 8 个架构上表现出一个尖锐的深度边界： $L \leq 24$  层的模型可以收敛， $L \geq 28$  层的模型全部发散。本文分析其数学根源：ALS 只修改 lm\_head（输出层），但 Transformer 的残差连接将这一局部变化从第  $L$  层逆向放大至第 0 层，放大倍数随层数指数增长—— $\rho^{L-1} \approx 1.08^{L-1}$ 。当  $L \geq 28$  时，放大因子超过 SGD 的梯度裁剪恢复能力，导致浅层参数无法与新 lm\_head 对齐，损失发散的恶性循环启动。我们通过 8 架构实证验证、消融实验和 LARS 优化器对比实验确认了这一机制，并讨论了三种修复路径。

## 1. 问题定义

### 1.1 Protocol A 的结构

Protocol A 的每个训练周期包含三个阶段：

| 阶段            | 操作            | 修改范围      | 具体实现                                                                                          |
|---------------|---------------|-----------|-----------------------------------------------------------------------------------------------|
| ALS (1 步)     | 闭式最小二乘求解      | 仅 lm_head | <pre>altopt/als.py:243 —<br/>for module in model: if "lm_head" in name:<br/>    solve()</pre> |
| SGD (\$k\$ 步) | 梯度下降消化 ALS 冲击 | 全部可训练参数   | 标准 CE loss → backward → clip → update                                                         |
| Perturb (1 步) | 参数噪声注入        | 全部可训练参数   | $\theta \leftarrow \theta + \epsilon, \epsilon \sim \mathcal{N}(0, \sigma^2)$                 |

ALS 阶段的核心数学操作（als.py:262-363）：

$$W_{\text{new}}^{(i)} = (X_m^T X_m + \lambda I)^{-1} X_m^T Y_m \quad \text{for block } i = 0, \dots, [V/b]$$

$$W_{\text{lm\_head}} \leftarrow (1 - \alpha) W_{\text{old}} + \alpha W_{\text{new}}, \quad \alpha = 0.01$$

其中  $V = 50257$  (vocab\_size),  $b = 1024$  (block\_size),  $\lambda = 10^{-3}$  (正则化),  $\alpha = 0.01$  (EMA 步长)。

## 1.2 关键观察

ALS 只动了  $\text{lm\_head}$  权重的约 1% (  $\alpha = 0.01$  )，但整个  $\text{lm\_head}$  矩阵的每个 block 都会被独立求解——约 50 个 block 各得到一个闭式解，加权平均后写入。前面 27 个 transformer 层的参数完全不变。

## 2. 数学机制：残差梯度放大

### 2.1 前向传播中的残差链

给定  $L$  层 Transformer:

$$\begin{aligned} \mathbf{h}_0 &= \text{Embedding}(x) \\ \mathbf{h}_{l+1} &= \mathbf{h}_l + \tilde{f}_l(\mathbf{h}_l; \mathbf{W}_l), \quad l = 0, \dots, L-1 \\ \mathbf{z} &= \text{lm\_head}(\mathbf{h}_L) = \mathbf{W}_L(\mathbf{h}_L) \cdot \text{RMSNorm}(\mathbf{h}_L) \end{aligned}$$

每一层  $f_l$  包含 Multi-Head Self-Attention 和 Feed-Forward Network。

### 2.2 反向传播中的梯度链

损失函数  $\mathcal{L} = \text{CrossEntropy}(\mathbf{z}, y)$  对 Layer 0 的梯度为:

$$\frac{\partial \mathcal{L}}{\partial \mathbf{h}_0} = \frac{\partial \mathcal{L}}{\partial \mathbf{h}_L} \cdot \prod_{l=0}^{L-1} \frac{\partial \mathbf{h}_{l+1}}{\partial \mathbf{h}_l}$$

由于  $\mathbf{h}_{l+1} = \mathbf{h}_l + f_l(\mathbf{h}_l)$ ，每一步的 Jacobian 为:

$$\frac{\partial \mathbf{h}_{l+1}}{\partial \mathbf{h}_l} = \mathbf{I} + \frac{\partial f_l(\mathbf{h}_l)}{\partial \mathbf{h}_l}$$

### 2.3 范数放大估计

对任意矩阵  $\mathbf{A}$ ， $\|\mathbf{I} + \mathbf{A}\| \leq 1 + \|\mathbf{A}\|$ 。当  $f_l$  的 Jacobian 范数为正值时，残差连接引入了乘性放大。

定义 per-layer 放大因子  $\rho = \frac{1}{L} \sum_{l=0}^{L-1} \|\mathbf{I} + \mathbf{J}_l\|$ ，则 Layer 0 的梯度范数相对于 Layer  $L$  的放大倍数为:

$$\gamma(L) \approx \bar{\rho}^L - 1$$

$\bar{\rho}$  的经验估计：从论文 § 6.2 的"消化时间"拟合得到  $\bar{\rho} \approx 1.08$  。验证方法：在 OPT-125m (12L) 和 Qwen2.5-0.5B (24L) 上测量 ALS 冲击后的 SGD 恢复所需步数， $\tau_{12} \approx 125$  ,  $\tau_{24} \approx 250$  , 二者比值为  $2.0 \approx \bar{\rho}^{12} = 1.08^{12} \approx 2.52$  （数量级一致）。

由此可计算各深度的放大倍数：

| 深度 \$L\$        | $\gamma = \bar{\rho}^L - 1$ | 说明          |
|-----------------|-----------------------------|-------------|
| 12 (GPT-2)      | $1.08^{12} \approx 2.33$    | 轻微放大        |
| 22 (TinyLlama)  | $1.08^{22} \approx 5.03$    | 中等放大        |
| 24 (Qwen0.5B)   | $1.08^{23} \approx 6.34$    | 显著放大        |
| 28 (Qwen7B)     | $1.08^{27} \approx 8.67$    | 超过 SGD 恢复阈值 |
| 32 (Mistral-7B) | $1.08^{31} \approx 11.77$   | 灾难性         |

3. 实证验证：八架构深度边界

3.1 100 步协议 A vs B 矩阵

**Table 1:** 8 个架构在 100 步、协议 A（ASP + Full-Rank）和协议 B（AdamW + Full-Rank）的 PPL 对比。

| 模型               | 参数量  | 层数 | GPU | A PPL  | B PPL | A-B Gap | 状态 |
|------------------|------|----|-----|--------|-------|---------|----|
| GPT-2            | 124M | 12 | —   | 185    | 8.3   | 177     | ✓  |
| OPT-125m         | 125M | 12 | —   | 651    | 22.3  | 629     | ✓  |
| TinyLlama-1.1B   | 1.1B | 22 | —   | 7,323  | 18.3  | 7,305   | ✓  |
| Qwen2.5-0.5B     | 494M | 24 | —   | 3,766  | 44.4  | 3,722   | ✓  |
| DeepSeek-R1-1.5B | 1.8B | 28 | ✓   | NaN    | 42    | NaN     | ✗  |
| SmolLM2-135M     | 135M | 30 | —   | 69,748 | 18    | 69,730  | ✗  |
| Mistral-7B       | 7.2B | 32 | ✓   | NaN    | 3,065 | NaN     | ✗  |
| Qwen2.5-7B       | 7.1B | 28 | ✓   | ~1.2M  | 1.25  | ~1.2M   | ✗  |




Figure 1: Protocol A vs B across 8 Architectures (100 steps).

### 关键特征：

- 尖锐边界：**所有  $\leq 24$  层模型收敛，所有  $\geq 28$  层模型发散。没有例外。
- SmolLM2-135M (30L)** 是半例外：PPL = 69,748（非 NaN），但这是基线的  $5\times$  恶化——协议 B 在同一模型上达到 PPL = 18。
- 边界与参数量无关：**TinyLlama (1.1B, 22L) 收敛，SmolLM2 (135M, 30L) 发散。决定因素是层数，不是参数量。

## 3.2 深度区间内的精细扫描

Table 2: P1.2 实验——4 模型在 200 步全 ASP 下的收敛行为。

| 模型             | 层数 | ASP PPL    | 基线 PPL | 基线改善         | 状态 |
|----------------|----|------------|--------|--------------|----|
| OPT-125m       | 12 | 106.9      | 231    | $2.2\times$  | ✓  |
| TinyLlama-1.1B | 22 | 15.5       | 146    | $9.4\times$  | ✓  |
| Qwen2.5-0.5B   | 24 | 18.0       | 411    | $22.8\times$ | ✓  |
| Qwen2.5-7B     | 28 | ~1,200,000 | 133    | —            | ✗  |

注意：OPT-125m 在 12 层的 PPL 为 106.9（弱于 22L/24L），这是因为 OPT-125m 的预训练质量较差——未经训练的基线 PPL 本身就是  $\sim 231$ 。TinyLlama 和 Qwen0.5B 经过更强预训练，ASP 的起点更好（更好的初始 hidden states  $\rightarrow$  ALS 解的质量更高  $\rightarrow$  SGD 消化更容易）。

## 3.3 Qwen2.5-7B 的详细发散曲线

Table 3: Qwen2.5-7B 协议 A 在 FSDP FULL\_SHARD 上的逐步 PPL（种子 42）。

| 步数  | PPL        | log10(PPL) |
|-----|------------|------------|
| 100 | 1,169,679  | 6.07       |
| 200 | 1,033,027  | 6.01       |
| 300 | 1,120,941  | 6.05       |
| 400 | ~1,200,000 | 6.08       |
| 704 | 终止         | —          |

无收敛趋势。PPL 在  $\log_{10} \approx 6.0 - 6.1$  附近上下震荡（约为基线 PPL=133 的  $10^4$  倍），每个 ALS 周期后产生新的开销峰值，SGD 消化期只能略微拉回。

共 11 次独立尝试、2 种分布式后端（DeepSpeed ZeRO-2 + PyTorch FSDP）全部失败，确认这是算法问题而非工程问题。

## 4. 梯度裁剪：恶性循环的触发点

### 4.1 标准 SGD 的裁剪机制

SGD 阶段的关键代码路径（`altopt/sgd.py:63-99`）：

```
forward → compute CE loss → backward → clip_grad_norm_(max_norm=1.0) → optimizer.step()
```

`clip_grad_norm_` 的工作原理：计算所有参数梯度的全局 L2 范数  $G_{total} = \sqrt{\sum_p \|\nabla_p\|^2}$ ，如果  $G_{total} > 1.0$ ，则对所有梯度等比缩放： $\nabla_p \leftarrow \nabla_p / G_{total}$ 。

### 4.2 剪切如何制造反馈循环

ALS 修改 `lm_head` 后，首轮 SGD 的梯度分布如下（示意）：

| 分量          | 未裁剪范数 | 裁剪后有效更新   | 问题                             |
|-------------|-------|-----------|--------------------------------|
| Layer 0 梯度  | ~0.87 | ~0.87/G   | ← 被深层"稀释"，有效更新过小               |
| Layer 14 梯度 | ~0.40 | ~0.40/G   | ← 中等                           |
| Layer 27 梯度 | ~0.10 | ~0.10/G   | ← 正常，离 <code>lm_head</code> 最近 |
| 全局范数 G      | ~1.5  | → 裁剪到 1.0 | ← 浅层贡献了大部分范数                   |

裁剪后：

Layer 0 有效更新量  $\approx 0.58$ （相对于其真实需要的梯度，远不够）

Layer 27 有效更新量  $\approx 0.07$ （相对于其真实需要的梯度，可能足够）

恶性循环的动力学：

- 1. ALS → lm\_head 变化 → 前向传播输出偏离 → loss ↑
- 2. SGD step 1: 浅层梯度被残差放大 → 全局裁剪削平浅层更新 → 浅层 "没学到" 如何配合新 lm\_head
- 3. SGD step 2: 浅层仍然不对齐 → loss 不降或回升 → 梯度更大 → 裁剪更严重
- 4. \$k\$ 步后：浅层仍未对齐 → 下一个 ALS 周期 → lm\_head 再次被修改 → 新一轮不对齐
- 5. 累积效应：每轮 ALS 都让 lm\_head 偏离一点点（ $\alpha = 0.01$ ），但浅层从未追上

4.3 跨种子方差验证

**Table 4:** 协议 A 的跨种子变异系数（CV%）。如果问题是纯随机的，CV 应该小。如果问题是反馈循环驱动的，CV 应该大。

| 步数  | OPT-125m A CV | Qwen0.5B A CV | GPT-2 A CV |
|-----|---------------|---------------|------------|
| 50  | 78.2%         | 152.3%        | —          |
| 100 | 22.7%         | 88.0%         | —          |
| 200 | 73.7%         | 157.8%        | —          |
| 400 | 69.4%         | 158.2%        | —          |
| 800 | 120.3%        | 44.9%         | —          |

对照：协议 B（AdamW + Full-Rank）在所有步数和种子上  $CV < 5\%$ 。

**解释：**ALS 的 Cholesky 分解对给定 batch 是确定性的，但 batch 的采样（shuffle seed）决定了 lm\_head 解出的方向。如果这个方向"碰巧"与当前浅层参数对齐，SGD 可以快速消化（低 PPL 种子）；如果方向相反，SGD 追不上（高 PPL 种子）。随着步数增加，小初始不对齐是否被放大取决于每次 ALS 的方向和 SGD 的恢复效率，这就是高 CV 的根源。

5. 消融实验：分离各组件的作用

5.1 P1.1 组件归因

**Table 5:** OPT-125m (12L) 上的 4 条件嵌套消融，200 步，N=3 seeds，FLOPs 匹配 ( $\pm 2\%$ )。

| 条件          | PPL (Mean ± SE) | Δ vs SGD-only | CV   | 解释                      |
|-------------|-----------------|---------------|------|-------------------------|
| SGD-only    | 59.4 ± 3.1      | — (baseline)  | 5.1% | 纯 SGD, 无 ALS, 无 Perturb |
| ALS+SGD     | 62.5 ± 0.4      | +3.1          | 0.6% | ALS→SGD 交替, 无 Perturb   |
| SGD+Perturb | 62.2 ± 0.6      | +2.8          | 0.9% | SGD + Perturb, 无 ALS    |
| Full ASP    | 69.0 ± 3.6      | +9.6          | 5.2% | ALS + SGD + Perturb     |

效应分解：

| 效应             | ΔPPL | 公式                           |
|----------------|------|------------------------------|
| ALS 主效应        | +3.1 | (ALS+SGD) - (SGD-only)       |
| Perturb 主效应    | +2.8 | (SGD+Perturb) - (SGD-only)   |
| 期望加性           | +5.9 | +3.1 + +2.8                  |
| ALS×Perturb 交互 | +3.6 | (Full ASP - SGD-only) - 期望加性 |
| Full ASP 总效应   | +9.6 | (Full ASP) - (SGD-only)      |

核心发现：

- 1. ALS 和 Perturb 单独使用时危害相近 (+3.1 vs +2.8 PPL)
- 2. 联合使用时产生拮抗交互：组合效应比加性预期大 61% (+9.6 vs +5.9)
- 3. **ALS+SGD (无 Perturb) CV = 0.6%**，Full ASP CV = 5.2%——不稳定性需要 ALS 和 Perturb 的共同存在
- 4. 去掉 Perturb 可以恢复 68% 的 PPL 损失：从 Full ASP 的 +9.6 降到 ALS+SGD 的 +3.1

**对深度模型的含义：** 在 12 层模型上，ALS 单独 +3.1 PPL 在 50 步 SGD 消化后可接受。在 28 层模型上，同样的 +3.1 PPL 按  $\rho^{27} \approx 8.7$  倍放大后等效于约 27 PPL 的冲击——SGD 根本无法在 50 步内消化。

5.2 LARS 优化器对比

LARS (Layer-wise Adaptive Rate Scaling) 对每个参数独立计算有效学习率：

$$\eta_{\text{local}} = \eta \cdot K \cdot \frac{\|\theta\|}{\|g\| + \lambda \|\theta\| + \epsilon}$$

其中  $\kappa$  是 trust coefficient (实验中扫描了 0.001、0.01、0.1) ,  $\eta$  是基础学习率。LARS 的核心优势在于浅层的大梯度会被自身的  $\|g\|/\|g\|$  比率自动调低有效学习率，深层的梯度也会被该比率独立调整——理论上可以抵消残差放大。

**Table 6:** Qwen2.5-0.5B (24L) 上 LARS vs 标准 SGD，200 步协议 A，4 周期。

| 周期        | SGD PPL          | LARS PPL ( $\kappa=0.001$ , no global clip) |
|-----------|------------------|---------------------------------------------|
| 1 (52 步)  | 79.0             | 296.9                                       |
| 2 (104 步) | 52.8             | 754,465                                     |
| 3 (156 步) | $\infty$ (发散)    | 573,056                                     |
| 4 (208 步) | $10^{223}$ (灾难性) | 161,674                                     |

分析：

- 1. **SGD** 在前两周期看似收敛（79→53），但在第三周期突然发散至  $\infty$ ——这正是反馈循环的临界点：累积了三轮 ALS 的不对齐后，SGD 的恢复机制崩溃
- 2. **LARS** 避免了  $\infty$  发散（全局 PPL 始终有界），但收敛到极差的值（~160k）——LARS 的逐层缩放防止了梯度爆炸但不能逆转已经积累的参数不对齐
- 3. **两个优化器都失败了**——证明问题不在优化器选择上，而在 ALS 本身制造的残差不对齐上

5.3 GPT-2 12L 对照

**Table 7:** GPT-2 (12L) 上 LARS vs 标准 SGD，200 步协议 A，4 周期。

| 周期 | SGD PPL     | LARS PPL |
|----|-------------|----------|
| 1  | 87.9        | 173.0    |
| 2  | 37.4        | 172.4    |
| 3  | 24.7        | 130.3    |
| 4  | <b>18.0</b> | 146.4    |

在浅层模型上，标准 SGD 稳定收敛（88→18，改善 4.9×），而 LARS 过补偿（逐层缩放给浅层过度分配更新预算 → 震荡）。**LARS 在残差放大不显著的深度上有负面影响。**

---

6. 完整实验证据链

| 实验          | 模型范围                           | 发现                              | 证据文件                                                    |
|-------------|--------------------------------|---------------------------------|---------------------------------------------------------|
| 八架构验证       | GPT-2 → Mistral-7B (12-32L)    | ≤24L 收敛, ≥28L 发散 (8/8)          | runs/cross_arch/                                        |
| 跨深度 ASP     | 4 模型 (12-28L)                  | OPT 12L 收敛, 28L 发散              | runs/p1.2_depth/results.json                            |
| Qwen7B FSDP | Qwen2.5-7B                     | PPL ~1.2M 无趋势                   | runs/qwen25_7b_800s/<br>Qwen25-7B_PA_800s_s42.json      |
| 组件归因        | OPT-125m (12L)                 | ALS +3.1, Perturb +2.8, 交互 +3.6 | runs/p1.1_ablation/results.json                         |
| LARS 优化器    | GPT-2 (12L) + Qwen0.5B (24L)   | LARS 在 12L 过补偿, 24L 避免 inf 但不收敛 | runs/lars_sanity_gpt2.json , runs/<br>lars_qwen05b.json |
| 跨种子方差       | OPT-125m + Qwen0.5B (50-800 步) | 协议 A CV 23-158%, 协议 B CV <5%    | runs/multi_seed_summary.json                            |

7. 理论模型：深度边界的解析解

7.1 临界条件

SGD 在一步内能恢复的最大扰动幅度受学习率  $\eta$ 、梯度裁剪阈值  $C_{max}$  和每层独立梯度与权重范数之比  $\mu_{min} = \min\|\nabla_i\|/\|\mathbf{W}\|$  的限制。

ALS 对 lm\_head 造成的有效扰动经 \$L\$ 层残差后到达 Layer 0 的幅度为：

$$A_{eff}(L) = \alpha \cdot \|\Delta\mathbf{W}_{lm}\| \cdot \bar{\rho}^{L-1}$$

其中  $\alpha=0.01$  为 EMA 步长。

SGD 能消化的最大扰动幅度为：

$$R_{max} = \eta \cdot \mu_{min} \cdot T_{SGD} \cdot \frac{C_{max}}{G_{total}}$$

其中  $T_{\text{SGD}}$  是每个周期的 SGD 步数（默认为 50）。

收敛的临界条件为  $A_{\text{eff}}(L) \leq R_{\text{max}}$ ，即：

$$L \leq L_{\text{max}} = 1 + \frac{\ln(R_{\text{max}}/(\alpha \cdot \|\Delta \mathbf{W}_{\text{lm}}\|))}{\ln \bar{\rho}}$$

代入实验拟合值（ $\bar{\rho} \approx 1.08$ ， $\alpha = 0.01$ ， $T_{\text{SGD}} = 50$ ， $\eta = 10^{-4}$ ）：

$$L_{\text{max}} \approx 1 + \frac{\ln(5 \times 10^{-3}/2 \times 10^{-3})}{\ln 1.08} \approx 1 + 11.9 \approx 13$$

解析预测的边界（~13 层）比实证边界（~26 层）保守。差异来源：(1)  $\bar{\rho}$  估计来自仅 2 个数据点（12L 和 24L 的消化时间），不确定性大；(2) 临界条件简化了 SGD 的多步累积效应。实证边界更可靠。

## 7.2 为什么 24L 能收敛但 28L 不能

24 层时， $\gamma \approx 6.3$ ，SGD 在 200-250 步内可以逐步缩小不对齐，尽管非单调（P1.2 实验中 Qwen0.5B 的 PPL = 18.0 验证了收敛但方差大）。

28 层时， $\gamma \approx 8.7$ ，梯度裁剪机制在  $\gamma \cdot G_{27} > c_{\text{max}}$  时开始系统性削平浅层更新，启动 § 4.2 所述的反馈循环。 $L^* \approx 26$  是  $\bar{\rho}^{L-1} \cdot G_{\text{tail}} = c_{\text{max}}$  的解，与 8 架构实证一致。

---

## 8. 解决方案与未来方向

### 8.1 已验证：SGD+Perturb（无 ALS）

在 GPT-2 (12L, Conv1D) 上，纯 SGD+Perturb（无 ALS）在 800 步达到 PPL =  $2.00 \pm 0.01$ ，优于 AdamW 的 PPL =  $2.78 \pm 0.01$ （改善 28%）。**这个方向没有深度限制**——因为不涉及 ALS 的闭式求解，所有参数通过梯度流同步更新，残差放大不会触发反馈循环。

8.2 理论可行但未验证

| 方向                 | 原理                                                   | 障碍                                                            |
|--------------------|------------------------------------------------------|---------------------------------------------------------------|
| 多层 ALS             | ALS 对最后 $k$ 层分别求解, $k$ 与 $L$ 成比例                     | 每层额外 ~7GB 内存（缓存激活 + Cholesky 工作空间），7B 模型当前 GPU 内存不可行          |
| 减小 ALS<br>$\alpha$ | $\alpha = 0.01 \rightarrow 0.0001$ ，逐步减小每次 ALS 的冲击幅度 | 需要 $100\times$ 的训练周期才能达到同样的 <code>lm_head</code> 变化量，训练时间不可接受 |
| LAMB 优化器           | 比 LARS 更强的层自适应 + 自适应学习率 + 动量                         | 7B 内存超限（同 LARS），且 LARS 实验已证明优化器改良不够                           |

8.3 已验证：隐式正则化是 ASP 的独特价值

尽管 ALS 在深模型上失败，P1.3 实验证明 ASP 的 SGD+Perturb 组合在 12 层模型上具有隐式正则化属性——跨域泛化显著优于 AdamW：

| 优化器       | WT2 PPL | C4 PPL | WT2/C4 比率 | 结论  |
|-----------|---------|--------|-----------|-----|
| ASP@800   | 75.1    | 48.1   | 1.56      | 泛化  |
| AdamW@200 | 18.5    | 92.4   | 0.20      | 过拟合 |

ASP 在 C4 跨域评估上达到  $1.9\times$  更好的 PPL（48.1 vs 92.4），代价是域内 PPL 差  $4.1\times$ 。WT2/C4 比率对 ASP 为 1.56（模型在 C4 上的表现好于 WT2 → 跨域泛化），对 AdamW 为 0.20（模型在 WT2 上的表现远好于 C4 → 域内过拟合）。




Figure 7: Theoretical Gradient Amplification vs Depth ( $\bar{\rho}=1.08$ ).

## 9. 总结

ALS 残差放大问题的完整因果链：

```
ALS 只求解 lm_head 的最小二乘解 ( $\alpha=0.01$ , 仅 1% 被采纳)
↓
lm_head 权重变化 → 通过残差连接被逐层放大 ( $\times \rho^{L-1}$ ,  $\rho \approx 1.08$ )
↓
SGD 反向传播中, 浅层梯度被放大  $\gamma(L) = \rho^{L-1}$  倍
↓
全局梯度裁剪到 1.0 → 浅层有效更新量被 "深层+浅层" 总范数中的浅层贡献稀释
↓
浅层参数无法与新 lm_head 对齐 → 损失不降或上升 → 梯度更大 → 反馈循环
↓
当  $L \leq 24$ :  $\gamma \leq 6.3$ , SGD 在 125-250 步内可勉强强化解
当  $L \geq 28$ :  $\gamma \geq 8.7$ , 超出 SGD 恢复阈值 → 发散 (8/8 架构验证)
```

**数据支撑：** - 8 架构验证：深度边界  $L^* \approx 26$ ,  $\leq 24L$  收敛,  $\geq 28L$  发散 - P1.2 跨深度 ASP: 4 模型验证非单调收敛→发散的转变 - P1.1 消融：ALS 是主要瓶颈 (+3.1 PPL), 与 Perturb 有拮抗交互 (+3.6 PPL) - LARS 实验：优化器改良不够 (24L 上无 inf 但不收敛) - 跨域正则化：ASP 的 Perturb 成分在 12L 上有独特价值 (C4 泛化  $1.9\times$  优于 AdamW)

**对后训练实践的启示：** 闭式最小二乘求解在深度 Transformer 上的适用性有一个明确的深度上限 (~26 层), 超出此上限的模型需要不同的优化策略——要么对所有层做 ALS (内存不可行), 要么完全放弃闭式求解改用纯梯度方法。